Alerte précoce du décrochage étudiant

Une classification explicable pour accompagner les étudiants à risque

Challenge 1, Data Mining, ENSI II3-IA | Mohamed Amine Belhedi | Cas 10 : décrochage étudiant

4 424
étudiants, 36 variables

32,1 %
d'abandons à détecter

0,936
AUC du meilleur modèle

86 %
des abandons détectés (seuil 0,3)

1. Problème métier

Une université veut repérer tôt les étudiants qui risquent d'abandonner leurs études, pour leur proposer un accompagnement (tutorat, aide financière, entretien avec un conseiller). Le modèle sert d'**alerte**. Étiqueter un étudiant « à risque » a des conséquences : ses décisions doivent pouvoir être expliquées.

2. Données

Jeu public UCI *Predict Students' Dropout and Academic Success* (un établissement portugais) : **4 424 étudiants**, 36 variables (profil, situation financière, parcours, résultats des deux semestres, contexte économique), aucune valeur manquante.

La cible a trois classes (abandon, diplômé, encore inscrit). Elle est ramenée à deux : **abandon** (1 421 étudiants, 32,1 %) contre les autres (3 003). Découpage stratifié 80 / 20 : 3 539 étudiants pour l'entraînement, 885 pour le test.

3. Modèles comparés

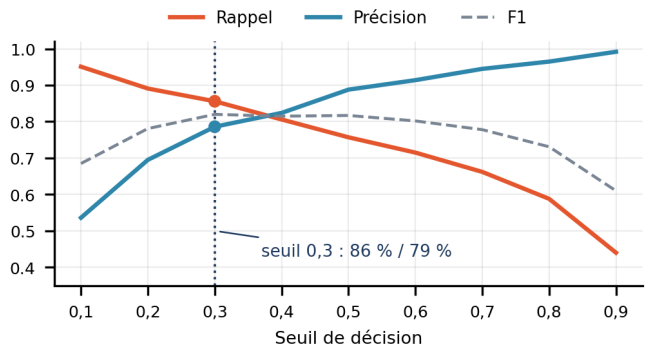
Cinq modèles, réglés par validation croisée, évalués sur les 885 étudiants de test.

Modèle	AUC test	PR-AUC	Lisibilité
XGBoost	0,936	0,909	Faible
Régression logistique	0,932	0,903	Très forte
Random Forest	0,926	0,895	Moyenne
k-NN	0,887	0,828	Faible
Arbre de décision	0,885	0,835	Forte

Meilleur modèle : XGBoost (AUC 0,936), mais il est à égalité avec la régression logistique : l'écart de 0,004 est trop faible pour être distingué sur 885 étudiants. Une recherche élargie sur XGBoost n'a gagné que 0,002 d'AUC en validation croisée, sans amélioration sur le test.

4. Résultats et choix du seuil

Le modèle donne une probabilité d'abandon ; l'alerte se déclenche au-dessus d'un seuil. Au seuil de 0,5, XGBoost détecte 76 % des abandons (précision 89 %). **Nous recommandons 0,3** :



À 0,3, le modèle détecte **86 % des abandons** (243 sur 284) avec une précision de 79 % : 309 étudiants signalés sur 885, dont 66 fausses alertes ; 41 abandons échappent encore. Un abandon non détecté coûte plus cher qu'un entretien inutile. Le seuil se règle selon la capacité de l'équipe d'accompagnement.

5. Ce que les données montrent déjà

Corrélations avec l'abandon, *avant* l'analyse SHAP. Les résultats académiques sont les signaux les plus forts : note (-0,57) et unités validées (-0,57) au 2e semestre, mêmes variables au 1er semestre (-0,48), frais de scolarité à jour (-0,43).

Les variables les plus associées à l'abandon sont l'âge à l'inscription (+0,25), la dette (+0,23) et le genre (+0,20). Une corrélation n'est pas une explication : c'est le rôle de SHAP.

6. Explications clés et analyse critique

À compléter après le module 5 (SHAP et LIME)

- variables qui pèsent le plus dans les décisions, et dans quel sens ;
- cohérence de SHAP, de LIME et de l'intuition métier ;
- poids des variables sensibles (genre, âge, nationalité, situation familiale) et conséquences pour l'équité ;
- actions concrètes tirées des explications.

7. Recommandations

- **Aide à la décision, pas décision automatique** : un conseiller examine chaque alerte avant toute démarche.
- **Seuil de 0,3**, à ajuster selon le nombre d'étudiants que l'équipe peut accompagner (309 signalés sur 885 à ce seuil).
- **Préférer la régression logistique** si la lisibilité prime : performance équivalente (0,932 contre 0,936) et coefficients lisibles par un non-spécialiste.
- **Alerte plus précoce** : réentraîner le modèle sans les variables du 2e semestre et mesurer ce qu'il perd (non réalisé).

8. Limites

- Les résultats du 2e semestre pèsent le plus mais arrivent tard : le modèle détecte bien l'abandon, pas forcément assez tôt.
- Les étudiants encore inscrits sont classés « sans abandon », alors que leur issue finale est inconnue.
- Des variables sensibles (genre, âge, nationalité, situation familiale) figurent dans le jeu : leur usage reste à examiner pour éviter toute discrimination.
- Un seul établissement : rien ne prouve que le modèle se généralise ailleurs.
- Une alerte est un signal de soutien, jamais un verdict à communiquer à l'étudiant.

Code, API FastAPI et application Streamlit : github.com/AmineBelhedi/challenge1-decrochage-xai

Application déployée : à compléter