Alerte précoce du décrochage étudiant

Une classification explicable pour accompagner les étudiants à risque

Challenge 1, Data Mining, ENSI II3-IA | Mohamed Amine Belhedi | Cas 10 : décrochage étudiant

4 424
étudiants, 36 variables

32,1 %
d'abandons à détecter

0,936
AUC du meilleur modèle

86 %
des abandons détectés (seuil 0,3)

1. Problème métier

Une université veut repérer tôt les étudiants qui risquent d'abandonner leurs études, pour leur proposer un accompagnement (tutorat, aide financière, entretien avec un conseiller). Le modèle sert d'**alerte**. Étiqueter un étudiant « à risque » a des conséquences : ses décisions doivent pouvoir être expliquées.

2. Données

Jeu public UCI *Predict Students' Dropout and Academic Success* (un établissement portugais) : **4 424 étudiants**, 36 variables (profil, situation financière, parcours, résultats des deux semestres, contexte économique), aucune valeur manquante.

La cible a trois classes (abandon, diplômé, encore inscrit). Elle est ramenée à deux : **abandon** (1 421 étudiants, 32,1 %) contre les autres (3 003). Découpage stratifié 80 / 20 : 3 539 étudiants pour l'entraînement, 885 pour le test.

3. Modèles comparés

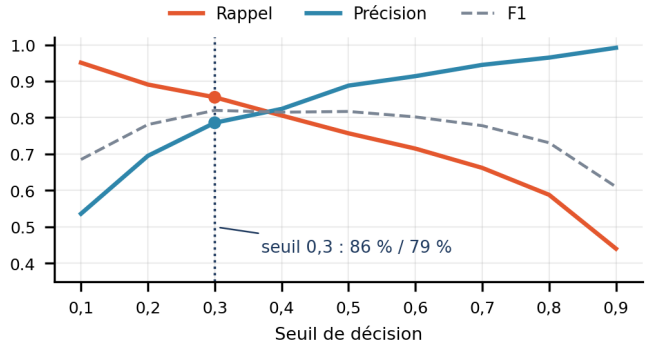
Cinq modèles, réglés par validation croisée, évalués sur les 885 étudiants de test.

Modèle	AUC test	PR-AUC	Lisibilité
XGBoost	0,936	0,909	Faible
Régression logistique	0,932	0,903	Très forte
Random Forest	0,926	0,895	Moyenne
k-NN	0,887	0,828	Faible
Arbre de décision	0,885	0,835	Forte

Meilleur modèle : XGBoost (AUC 0,936), mais il est à égalité avec la régression logistique : l'écart de 0,004 est trop faible pour être distingué sur 885 étudiants. Une recherche élargie sur XGBoost n'a gagné que 0,002 d'AUC en validation croisée, sans amélioration sur le test.

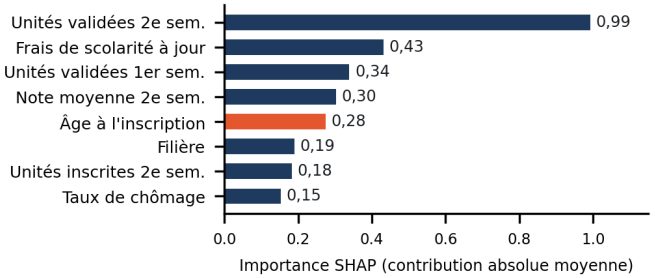
4. Résultats et choix du seuil

Le modèle donne une probabilité d'abandon ; l'alerte se déclenche au-dessus d'un seuil. Au seuil de 0,5, XGBoost détecte 76 % des abandons (précision 89 %). **Nous recommandons 0,3** :



À 0,3, le modèle détecte **86 % des abandons** (243 sur 284) avec une précision de 79 % : 309 étudiants signalés sur 885, dont 66 fausses alertes ; 41 abandons échappent encore. Un abandon non détecté coûte plus cher qu'un entretien inutile. Le seuil se règle selon la capacité de l'équipe d'accompagnement.

5. Ce que le modèle utilise (SHAP)



Les décisions reposent surtout sur les résultats académiques et le paiement des frais. SHAP et l'importance par permutation donnent le même top 4. **Effet de seuil** : avec 0 unité validée au 2e semestre le risque s'envole ; à partir de 6 unités il devient faible. Des frais non à jour sont le plus fort signal pris isolément ; la bourse protège. En orange : une variable sensible.

6. Cohérence des explications

SHAP et LIME s'accordent sur le **sens** de chaque effet (20 comparaisons sur 20) et sur les causes de l'étudiant signalé à raison. Pour les étudiants à faible risque, les classements divergent davantage et LIME est moins stable (jusqu'à 3 listes différentes sur 5 exécutions) : SHAP sert de référence. Les deux concordent avec l'intuition métier : échec académique et frais impayés augmentent le risque, bourse et unités validées le réduisent.

7. Équité et variables sensibles

Les variables sensibles pèsent peu (**9,4 %** de l'importance SHAP : âge 6,1 %, genre 2,8 %) ; inverser le genre ne change que 25 décisions sur 885. Mais les erreurs diffèrent selon les groupes : fausses alertes de **18,9 % contre 7,7 %** selon le genre (abandons réels : 45,5 % contre 24,5 %), et abandons des 22 ans ou moins détectés à **76 % contre 94 %** au-delà.

Le modèle s'appuie aussi sur la profession de la mère : un code de 22 étudiants sans aucun abandon réduit à lui seul le risque prédit. Retirer les variables sensibles et celles des parents ne coûte rien (AUC 0,936) mais ne supprime pas l'écart de détection selon l'âge.

8. Recommandations

- **Aide à la décision** : un conseiller examine chaque alerte. Seuil de 0,3, à ajuster selon la capacité d'accompagnement.
- **Préférer la régression logistique** : performance équivalente (AUC 0,932 contre 0,936) et coefficients lisibles sans outil d'explication. XGBoost avec SHAP reste possible.
- **En production**, ne garder que des variables académiques et financières (aucun coût mesuré) et suivre chaque semestre les erreurs par genre et par âge, avec un suivi renforcé des 22 ans ou moins en difficulté.
- **Actions** : frais impayés, contact du service financier (échéancier, bourse) ; 0 à 2 unités validées, tutorat ; aucune évaluation passée, étudiant probablement parti : appel immédiat.
- **Alerte plus précoce** : réentraîner sans les variables du 2e semestre (non réalisé).

9. Limites

- Les résultats du 2e semestre pèsent le plus mais arrivent tard : le modèle détecte, pas forcément assez tôt.
- Certains abandons n'ont aucun signal : un étudiant ayant validé 7 unités à chaque semestre, boursier, frais à jour, a décroché sans être détecté (les données couvrent deux semestres).
- Les étudiants encore inscrits sont classés « sans abandon » alors que leur issue est inconnue. Un seul établissement.
- Une alerte est un signal de soutien, jamais un verdict à communiquer à l'étudiant.